الجامعة الدولية للعلوم والنهضة
كلية الهندسة المعلوماتية

ورقة بحث علمية

نظام ذكي للتنبؤ باحتمالية التأخرفي سداد الأقساط الدراسية باستخدام خوارزميات تعلم الآلة

اعداد

رولا الاسماعيل _ دعاء الشاشو _ نسرين الكردي

هنان الرجب _ نهلة العدل

اشراف

أ. عبد المهيمن الاسماعيل

2026

الفهرس

الملخص (Abstract) 2

1. المقدمة (Introduction) 3

مشكلة البحث وأسئلته 3

أهداف البحث 4

2. الإطار النظري والمفاهيم الأساسية (Theoretical Framework) 4

◈ التعلم الآلي ومهمة التصنيف 4

◈ اختيار الميزات: المفهوم والدوافع والطرق 5

◈خوارزمية شجرة القرار 5

◈ مقاييس تقييم أداء التصنيف 5

◈ مسرد المصطلحات الأساسية (Glossary of Terms) 6

3. الدراسات السابقة (Literature Review) 7

4. منهجية البحث (Research Methodology) 7

مجموعة البيانات (Dataset) 7

المعالجة المسبقة للبيانات (Preprocessing) 9

تصميم التجربة (Experimental Setup) 10

الأدوات والبرمجيات المستخدمة 10

5. النتائج والمناقشة (Results & Discussion) 11

أثر الاختيار على أداء النموذج 12

تحليل مصفوفة الالتباس (Confusion Matrix Analysis) 13

مناقشة النتائج 13

6. الخاتمة والتوصيات (Conclusion & Recommendations) 14

حدود الدراسة (Limitations): 14

التوصيات والأعمال المستقبلية: 15

المراجع (References) 16

الملخص (Abstract)

تواجه المؤسسات التعليمية تحديًا في التنبؤ المبكر بالطلبة المعرضين للتأخر في سداد الأقساط الدراسية، ولا سيما عندما ترتبط عملية السداد بمجموعة متداخلة من العوامل الأكاديمية والاجتماعية والمالية. تهدف هذه الدراسة إلى تطوير نظام ذكي يعتمد على تقنيات تعلم الآلة للتنبؤ باحتمالية تأخر الطالب في سداد القسط الدراسي، اعتمادًا على مجموعة من الخصائص المرتبطة بالأداء الأكاديمي، والوضع المالي للأسرة، والسجل السابق للسداد، والسكن والموقع الجغرافي. تكونت مجموعة البيانات الأصلية من 264 سجلًا، وخضعت لعمليات استكشاف وتنظيف ومعالجة مسبقة شملت معالجة القيم غير المنطقية، وتوحيد البيانات الفئوية، وإزالة ثلاثة سجلات مكررة، لتصبح البيانات المستخدمة في النمذجة 261 سجلًا. تم تعريف المسألة بوصفها مسألة تصنيف ثنائي، بحيث تمثل الفئة (0) السداد في الموعد، وتمثل الفئة (1) التأخر في السداد.

_ تمت مقارنة ثلاث خوارزميات هي Logistic Regression و Support Vector Machine و Random Forest باستخدام التحقق المتقاطع الطبقي اربع طيات، وبالاعتماد على Accuracy و Precision و Recall و F1-score. أظهرت النتائج أن Random Forest حقق أفضل F1-score في التحقق المتقاطع بقيمة 0.573 تقريبًا، ولذلك تم اعتماده نموذجًا نهائيًا. وعلى مجموعة الاختبار حقق النموذج Accuracy بلغت 75.47%، و Recall لفئة التأخر بلغت 66.67%، و F1-score بلغت 55.17%. كما أظهر تحليل أهمية الخصائص أن مؤشرات تاريخ السداد السابق كانت الأكثر اعتمادًا عليها في عملية التنبؤ. تشير النتائج إلى إمكانية استخدام تعلم الآلة كأداة مساعدة للكشف المبكر عن حالات التأخر المحتملة، مع التأكيد على أن مخرجات النظام احتمالية ولا ينبغي استخدامها منفردة لاتخاذ قرارات مالية أو إدارية نهائية.

- الكلمات المفتاحية: تعلم الآلة، السداد الدراسي، Random Forest، التصنيف الثنائي، التنبؤ بالتأخر، تحليل بيانات الطلبة.

1. المقدمة (Introduction)

أدى التوسع في تطبيق تقنيات الذكاء الاصطناعي وتعلم الآلة إلى ظهور إمكانات جديدة للاستفادة من البيانات المتراكمة داخل المؤسسات التعليمية في بناء أنظمة داعمة لاتخاذ القرار. ولم تعد تطبيقات تحليل بيانات الطلبة مقتصرة على التنبؤ بالتحصيل الأكاديمي، بل يمكن توظيفها لدراسة أنماط أخرى مرتبطة بالطالب، من بينها انتظامه في سداد الالتزامات المالية.

يعد التأخر في سداد الأقساط من المشكلات التي قد تؤثر في التخطيط المالي للمؤسسة التعليمية وفي قدرة الطالب نفسه على متابعة الإجراءات المرتبطة بالتسجيل. ويصعب تفسير هذه المشكلة اعتمادًا على عامل منفرد، إذ يمكن أن تكون مرتبطة بالدخل الأسري أو بتاريخ السداد السابق أو بظروف الطالب الأكاديمية والاجتماعية.

من هنا جاءت فكرة هذه الدراسة لبناء نموذج تعلم آلة يتعامل مع المشكلة على أنها مسألة تصنيف ثنائي (Binary Classification)، بحيث يتعلم النموذج من الحالات السابقة ويقدر احتمال وقوع التأخر في السداد لحالة جديدة، عبر مقارنة ثلاث خوارزميات تختلف في آلياتها الرياضية هي Random Forestg Support Vector Machineg Logistic Regression.

مشكلة البحث وأسئلته

تتمثل مشكلة البحث في السؤال الرئيس الآتي: **هل يمكن استخدام مجموعة من البيانات الأكاديمية والمالية والاجتماعية والسلوكية للطالب للتنبؤ باحتمالية تأخره في سداد القسط الدراسي؟**

- ما مدى قدرة خوارزميات التصنيف المختلفة على اكتشاف الطلبة المعرضين للتأخر؟
- أي من النماذج المختبرة يحقق أفضل توازن بين Precision وRecall؟
- ما الخصائص الأكثر تأثيرًا في قرار النموذج؟

أهداف البحث

يهدف البحث إلى بناء نظام تعلم آلة متكامل للتنبؤ بسلوك سداد الأقساط الدراسية، ويتحقق ذلك من خلال الأهداف الفرعية الآتية:

- ✦ استكشاف مجموعة البيانات وتنظيفها وتوحيد قيمها ومعالجة القيم غير المنطقية.
- ✦ تجهيز الخصائص الرقمية والفئوية بالشكل المناسب لنماذج تعلم الآلة.
- ✦ تدريب ومقارنة ثلاثة نماذج تصنيف هي Logistic Regression وSVM وRandom Forest.
- ✦ اختيار النموذج الأفضل وفق F1-score مع الاستفادة من بقية مقاييس التقييم.
- ✦ تحليل أهم الخصائص التي يعتمد عليها النموذج النهائي في التنبؤ.

2. الإطار النظري والمفاهيم الأساسية (Theoretical Framework)

يستعرض هذا القسم أهم المفاهيم النظرية التي تستند إليها الدراسة، بدءًا من مهمة التصنيف في تعلم الآلة، مرورًا بمفهوم اختيار الميزات ومقاييس تقييم أداء النموذج، وانتهاءً بمسرد موجز للمصطلحات المستخدمة.

◈ التعلم الآلي ومهمة التصنيف

التعلم الآلي (Machine Learning) هو فرع من الذكاء الاصطناعي تتعلم فيه البرامج من الأمثلة والبيانات بدل برمجتها بقواعد صريحة جاهزة. ومن أشهر مهامه مهمة التصنيف (Classification)، وفيها يتعلم النموذج من أمثلة سابقة معلومة الفئة (بيانات التدريب) كيف يتنبأ بفئة أمثلة جديدة لم يرها من قبل. وفي هذه الدراسة، العينة هي الطالب، والفئة المطلوب التنبؤ بها هي حالة السداد: (0) سداد في الموعد، أو (1) تأخر في السداد؛ أي أن المسألة صيغت بوصفها تصنيفًا ثنائيًا (Binary Classification).

◈ اختيار الميزات: المفهوم والدوافع والطرق

اختيار الميزات (Feature Selection) هو عملية انتقاء مجموعة جزئية من الميزات الأصلية تكون الأكثر فائدة للتنبؤ، مع إهمال الميزات الضعيفة أو المكررة. وتنبع أهميته من دوافع عدة: تقليل الضوضاء الناتجة عن الميزات غير المرتبطة بالهدف، والحد من فرط التخصيص (Overfitting)، وتسريع التدريب، وتسهيل تفسير النموذج على البشر. وتصنف طرق اختيار الميزات عادة في ثلاث عائلات: طرق التصفية (Filter) التي تقيم كل ميزة إحصائيًا بمعزل عن خوارزمية التعلم، وطرق الالتفاف (Wrapper) التي تجرب مجموعات مختلفة من الميزات على النموذج نفسه، والطرق المدمجة (Embedded) التي يجري فيها تقدير أهمية الميزة ضمن عملية بناء النموذج ذاتها.

اعتمدت هذه الدراسة على 20 ميزة موزعة على أربعة محاور (أكاديمية، مالية وأسرية، سجل سداد، سكن وموقع) دون إجراء استبعاد مسبق لأي منها، ثم استخدمت طريقة مدمجة قائمة على النموذج، هي تحليل أهمية الميزات بالتبديل (Permutation Importance)، لتقدير مدى اعتماد النموذج النهائي على كل ميزة بعد التدريب، بدلا من إجراء اختيار للميزات قبل التدريب.

◈خوارزمية شجرة القرار

شجرة القرار (Decision Tree) نموذج تصنيف على هيئة شجرة من الأسئلة المتسلسلة عن قيم الميزات؛ كل عقدة داخلية تمثل سؤالا، وكل فرع يمثل إجابة، وكل ورقة في نهاية المسار تمثل الفئة المتوقعة. وترتبط هذه الخوارزمية مباشرة بهذه الدراسة لأن الغابة العشوائية (Random Forest) — النموذج الذي اعتمد نهائيًا — هي طريقة تجميعية تبنى من عدد كبير من أشجار القرار المدربة على عينات وخصائص عشوائية من البيانات، ثم تدمج مخرجاتها للوصول إلى قرار أكثر استقرارًا وأقل عرضة لفرط التخصيص من شجرة قرار مفردة [1].

◈ مقاييس تقييم أداء التصنيف

بعد تدريب النموذج يُقيَّم أداؤه على بيانات اختبار لم يرها أثناء التدريب، بمقارنة الفئات الحقيقية بالفئات المتنبأ بها ضمن مصفوفة الالتباس (Confusion Matrix)، وتشتق منها المقاييس الآتية:

- **الدقة Accuracy** نسبة التنبؤات الصحيحة إلى العدد الكلي للعينات.

- **الضبط Precision** من بين العينات التي صنفها النموذج في فئة ما، كم كانت نسبة المصيب منها فعلا؟
- **الاستدعاء Recall** من بين العينات المنتمية فعلا إلى فئة ما، كم التقط النموذج منها؟
- **مقياس F1** المتوسط التوافقي للضبط والاستدعاء:

$$F1 = 2 \times (Precision \times Recall) / (Precision + Recall)$$

ولأن الفئات في هذه الدراسة غير متوازنة (سداد في الموعد مقابل تأخر)، أضيف مقياس Accuracy ومنحنى Precision-Recall لتقييم قدرة النموذج على التمييز بمعزل عن أثر عدم التوازن على Accuracy وحدها [4].

◈ مسرد المصطلحات الأساسية (Glossary of Terms)

المصطلح بالعربية	المصطلح بالإنجليزية	التعريف العلمي المبسط
التعلم الآلي	Machine Learning	تعلم البرامج من البيانات دون برمجة صريحة للقواعد.
التصنيف الثنائي	Binary Classification	التنبؤ بإحدى فئتين فقط، هنا: سداد في الموعد أو تأخر.
الميزة	Feature	خاصية قابلة للقياس تصف العينة، مثل الدخل الشهري للأسرة.
اختيار الميزات	Feature Selection	انتقاء الميزات الأكثر فائدة وإهمال الأقل أهمية.
فرط التخصيص	Overfitting	حفظ النموذج تفاصيل بيانات التدريب وضعف تعميمه.
الغابة العشوائية	Random Forest	نموذج تجميعي من أشجار قرار متعددة.
مصفوفة الالتباس	Confusion Matrix	جدول يقارن الفئات الحقيقية بالفئات المتنبأ بها.
منحنى ROC	ROC Curve	علاقة بين معدل الإيجابيات الصحيحة والخاطئة عند تغيير العتبة.

3. الدراسات السابقة (Literature Review)

قدّم بريمان [1] الغابة العشوائية (Random Forest) بوصفها طريقة تجميعية تعتمد على بناء عدد كبير من أشجار القرار على عينات وخصائص عشوائية ثم دمج مخرجاتها، وأظهر أن هذا التجميع يحسّن القدرة على التعميم مقارنة بشجرة قرار مفردة. وفي الاتجاه نفسه، طرح كورتيس وفابنيك [2] آلة المتجهات الداعمة (SVM) القائمة على إيجاد حد فاصل بأقصى هامش ممكن بين الفئات، وهي من أكثر الخوارزميات استخدامًا في مسائل التصنيف الثنائي متوسطة الحجم.

ويُعد الانحدار اللوجستي، كما وثّقه هوسمر وزملاؤه [3]، من أقدم الأساليب الإحصائية وأكثرها انتشارًا في نمذجة متغيرات الاستجابة الثنائية، ويُستخدم غالبًا نموذجًا مرجعيًا تُقاس إليه أداء النماذج الأكثر تعقيدًا. أما في جانب التقييم، فقد بيّن سايتو وريمسماير [4] أن منحنى Precision-Recall أكثر إفادة من منحنى ROC عند تقييم مصنفات ثنائية على بيانات غير متوازنة الفئات، وهي حالة تنطبق مباشرة على مسألة التأخر في السداد التي تمثل فيها حالات التأخر أقلية.

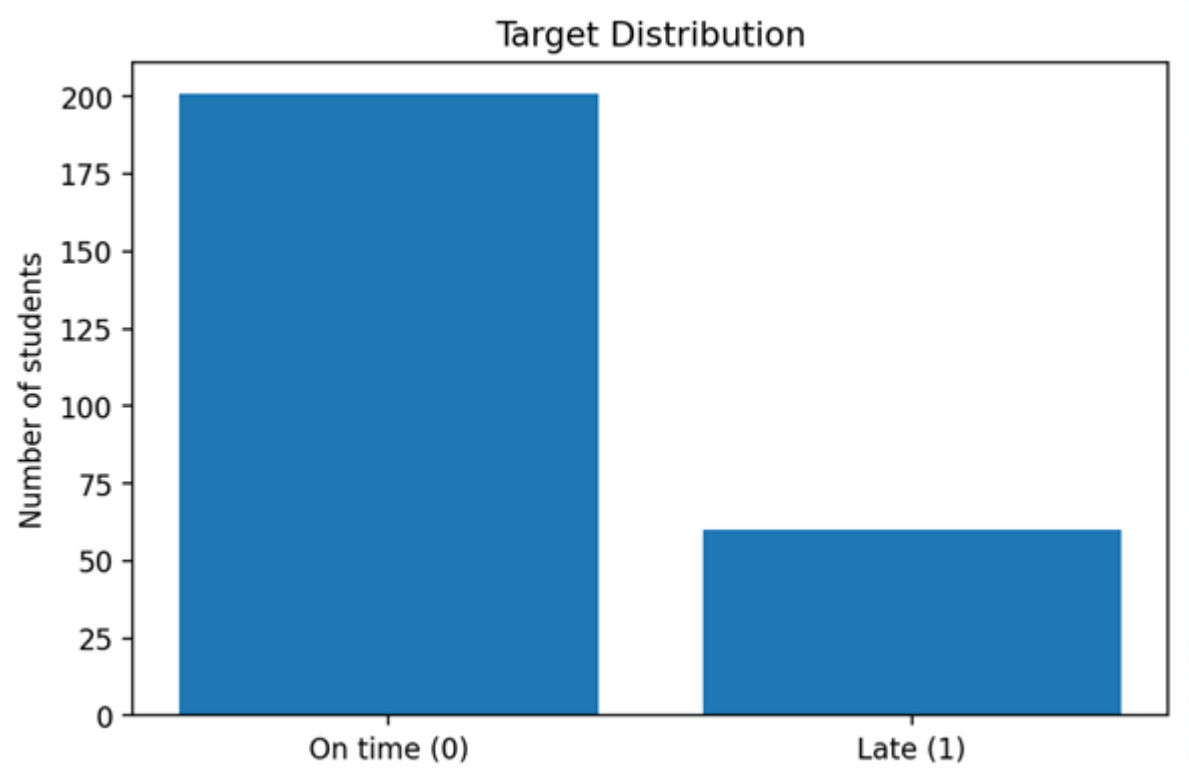
فجوة البحث: ركّزت هذه الدراسات على الأساس الرياضي والإحصائي لكل خوارزمية أو مقياس تقييم على حدة، بينما تطبّق هذه الورقة هذه الأدوات مجتمعة — مقارنة ثلاث خوارزميات تصنيف تحت ظرف عدم توازن حقيقي في الفئات — على مسألة تطبيقية جديدة نسبيًا في أدبيات التنقيب في البيانات التعليمية، وهي التنبؤ المبكر بالتأخر في سداد الأقساط الدراسية، مع تحليل أهمية الخصائص وربط النتيجة بالسياق المؤسسي.

4. منهجية البحث (Research Methodology)

مجموعة البيانات (Dataset)

تضمنت مجموعة البيانات الأصلية 264 سجلًا للطلبة، واشتملت على بيانات أكاديمية ومالية واجتماعية وسلوكية. وخلال مرحلة الاستكشاف تم اكتشاف ثلاثة سجلات مكررة بصورة كاملة إلى جانب عدد من القيم غير المتجانسة أو غير المنطقية التي تطلبت التنظيف والتحقق. وبعد إزالة

السجلات المكررة أصبحت البيانات المستخدمة في النمذجة 261 سجلًا. تم تعريف المتغير الهدف late_payment بحيث تشير القيمة 0 إلى السداد في الموعد وتشير القيمة 1 إلى التأخر في السداد.



يبين الشكل وجود عدم توازن واضح بين الفئتين؛ إذ تمثل حالات السداد في الموعد نحو 77% من السجلات، بينما تمثل حالات التأخر نحو 23%. وهذه الملاحظة مهمة لأن الاعتماد على Accuracy وحدها قد يعطي تصورًا غير كاف عن جودة المصنف.

اعتمد النظام على 20 متغيرًا مدخلًا تغطي أربعة محاور رئيسة كما يبين الجدول الآتي:

المحور الأساسي	المتغيرات المستقلة المشمولة في النموذج
البيانات الأكاديمية	الفرع الدراسي، السنة الدراسية، عدد الساعات المسجلة، المعدل التراكمي، نسبة الحضور، والعمل إلى جانب الدراسة.
البيانات المالية والأسرية	قيمة القسط التقريبية، قيمة القسط الفصلي، المسؤول عن دفع القسط، الدخل الشهري للأسرة، عدد أفراد الأسرة العاملين، وعدد الإخوة في التعليم الجامعي الخاص.
سجل السداد	وجود تأخر سابق، وجود أقساط سابقة غير مسددة، عدد مرات التأخر، أقصى مدة تأخر، وعدد مرات السداد في الموعد.
السكن والموقع	المحافظة، نوع السكن، والمسافة بين السكن والجامعة.

المعالجة المسبقة للبيانات (Preprocessing)

سبقت مرحلة التدريب مجموعة من عمليات معالجة البيانات بهدف تحسين جودتها ومنع انتقال الأخطاء الموجودة في البيانات الخام إلى النموذج. شملت المعالجة إزالة السجلات المكررة، وتنظيف أسماء الأعمدة، وتوحيد القيم الفئوية، وتحويل الأعمدة الرقمية إلى أنواع مناسبة، والتعامل مع القيم غير الصالحة أو غير المنطقية، ثم تجهيز المتغيرات الفئوية والرقمية بالطريقة المناسبة داخل مسار التدريب.

تم كذلك فصل المتغير الهدف عن المتغيرات المستقلة قبل التدريب لتجنب تسرب البيانات (Data Leakage)، وقد روعي أن المتغيرات المتعلقة بالتأخر تشير إلى السجل السابق للطالب، وليس إلى حالة القسط الهدف نفسها.

تصميم التجربة (Experimental Setup)

قورنت في هذه الدراسة ثلاث خوارزميات تختلف في آلياتها الرياضية: (أ) الانحدار اللوجستي (Logistic Regression)، ويُستخدم بوصفه نموذجًا مرجعيًا مناسبًا للتصنيف الثنائي [3]؛ (ب) آلة المتجهات الداعمة (Support Vector Machine)، التي تبني حد قرار يفصل بين الفئات مع تعظيم الهامش الفاصل [2]؛ (ج) الغابة العشوائية (Random Forest)، التي تجمع عددًا من أشجار القرار المبنية على عينات وخصائص عشوائية ثم تدمج مخرجاتها للوصول إلى قرار نهائي أكثر استقرارًا [1].

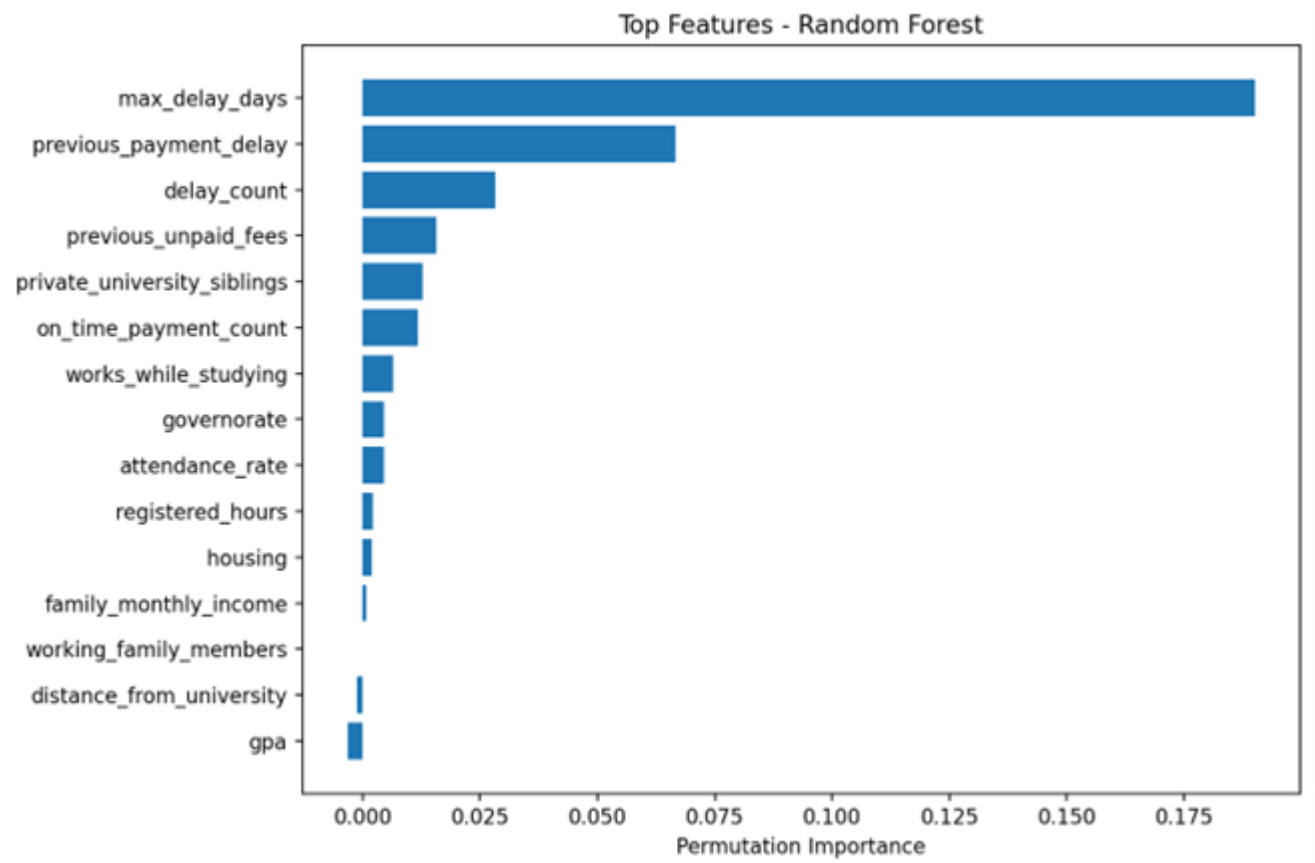
ونظرًا لعدم توازن الفئات، لم تعتمد الدراسة على Accuracy وحدها؛ فاستخدم التحقق المتقاطع الطبقي بخمس طيات (Stratified 5-Fold Cross Validation) للمحافظة على توزيع الفئات داخل طيات التحقق، واعتمد F1-score لفئة التأخر معيارًا رئيسيًا للمفاضلة بين النماذج الثلاثة، إلى جانب Accuracy وRecall وPrecision.

$$F1 = 2 \times (Precision \times Recall) / (Precision + Recall)$$

الأدوات والبرمجيات المستخدمة

نُفذت التجربة بلغة Python، باستخدام مكتبة pandas لمعالجة البيانات، ومكتبة scikit-learn [5] لبناء النماذج الثلاثة وحساب مقاييس التقييم وإجراء التحقق المتقاطع، ومكتبة joblib لحفظ النموذج النهائي، إضافة إلى أدوات الرسم البياني لإنتاج أشكال توزيع البيانات ومصفوفة الالتباس ومنحنيي ROC وPrecision-Recall.

5. النتائج والمناقشة (Results & Discussion)



- **شكل (2):** أهم الخصائص وفق Permutation Importance لنموذج Random Forest.

أظهر تحليل Permutation Importance أن الخاصية max_delay_days كانت الأكثر تأثيرًا بفارق واضح، تلتها previous_payment_delay ثم delay_count وprevious_unpaid_fees. ويشير ذلك إلى أن السجل التاريخي للسداد يمثل مصدرًا مهمًا للمعلومات بالنسبة للنموذج، بينما تراجعت أهمية عدد من الميزات الديموغرافية والسكنية إلى مراتب متأخرة. ويجب التنبيه إلى أن أهمية الخاصية تقيس مدى اعتماد النموذج عليها في التنبؤ، ولا تثبت وجود علاقة سببية بينها وبين التأخر [6].

أثر الاختيار على أداء النموذج

يلخص الجدول الآتي متوسط نتائج التحقق المتقاطع الطبقي بخمس طيات للنماذج الثلاثة، وتظهر النتائج أن Random Forest حقق أعلى F1-score وأعلى Accuracy ، مع تقارب نسبي في الأداء العام بين النماذج الثلاثة:

خوارزمية النموذج	Accuracy	Precision	Recall	F1-score
Random Forest	75.53%	47.90%	71.33%	57.29%
SVM	75.05%	46.87%	71.33%	56.43%
Logistic Regression	73.12%	43.77%	65.11%	52.25%

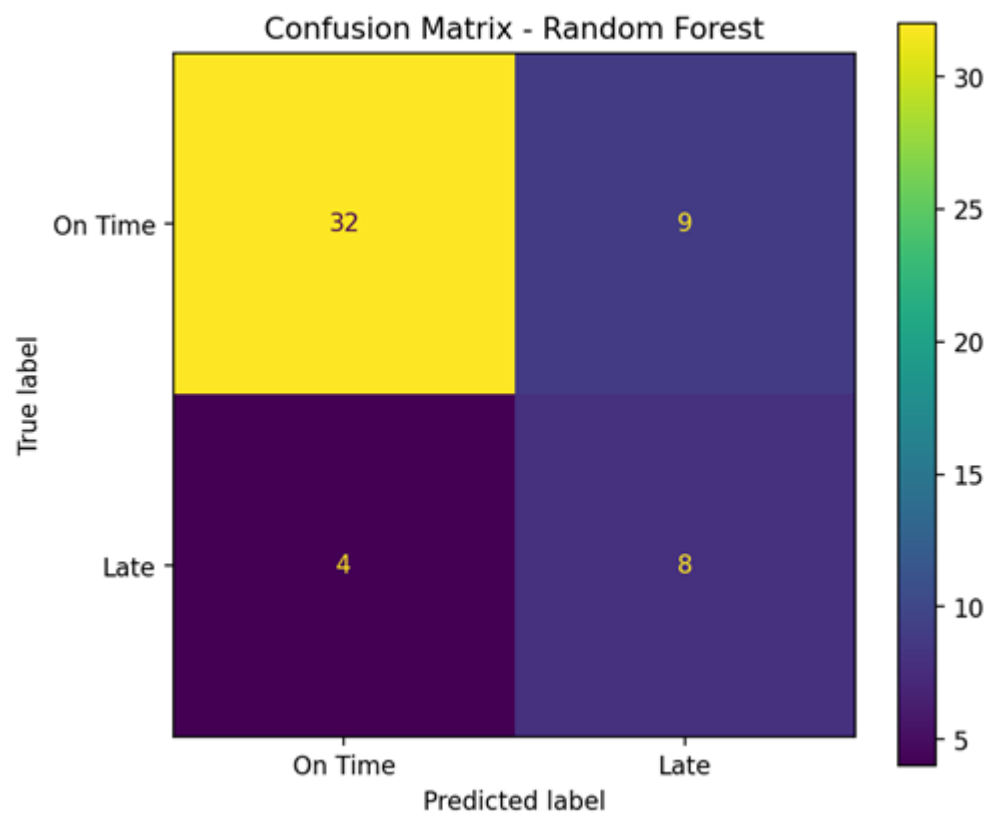
جدول (1): متوسط نتائج التحقق المتقاطع بخمس طيات للنماذج الثلاثة.

بناءً على معيار الاختيار المحدد مسبقًا، اعتمد Random Forest نموذجًا نهائيًا. وحقق هذا النموذج على مجموعة الاختبار المستقلة النتائج الآتية:

مقياس التقييم المستقل	القيمة المحققة (Test Set)
Accuracy	75.47%
Precision لفئة التأخر	47.06%
Recall لفئة التأخر	66.67%
F1-score لفئة التأخر	55.17%
Average Precision	47.46%

جدول (2): مقاييس أداء نموذج Random Forest على مجموعة الاختبار المستقلة.

تحليل مصفوفة الالتباس (Confusion Matrix Analysis)



- **شكل (3):** مصفوفة الالتباس لنموذج Random Forest على مجموعة الاختبار.

توضح مصفوفة الالتباس أن النموذج صنف 32 حالة سداد في الموعد بصورة صحيحة، وصنف 9 حالات سداد في الموعد على أنها تأخر. كما اكتشف 8 حالات تأخر بصورة صحيحة، في حين أخفق في اكتشاف 4 حالات تأخر وصنفها على أنها سداد في الموعد.

Recall(Late) = 8 / (8 + 4) = 66.67%

مناقشة النتائج

تكشف النتائج عن نقطة محورية مفادها أن Accuracy ليست المقياس الوحيد المناسب لهذا المشروع؛ ففي مجموعة الاختبار توجد 41 حالة سداد في الموعد مقابل 12 حالة تأخر، وبالتالي فإن مصنفًا ساذجًا يتنبأ دائمًا بالسداد في الموعد يحقق Accuracy مقدارها 77.36% تقريبًا، وهي أعلى قليلًا من Accuracy النموذج النهائي، لكنه سيحقق Recall يساوي صفرًا لفئة التأخر.

Baseline Accuracy = 41 / 53 ≈ 77.36%

في المقابل اكتشف Random Forest ثمان حالات من أصل 12 حالة تأخر، ما يجعل اختيار النموذج على أساس F1-score وRecall أكثر اتساقا مع الهدف العملي للنظام. كما أن تقارب F1-score بين التحقق المتقاطع (نحو 0.573) والاختبار المستقل (نحو 0.552) لا يشير إلى فجوة تعميم كبيرة بصورة واضحة، إلا أن صغر حجم العينة يستدعي الحذر عند تعميم هذه الملاحظة على بيانات جديدة.

وتعكس أهمية متغيرات تاريخ السداد منطقا تنبؤيًا معقولا، إذ يمكن للسلوك السابق أن يحمل معلومات عن السلوك المستقبلي؛ غير أن استخدام هذه الخصائص يجب أن يظل ضمن إطار التنبؤ لا السببية، وأن تخضع أي قرارات لاحقة لمراجعة بشرية وسياق مؤسسي مناسب.

6. الخاتمة والتوصيات (Conclusion & Recommendations)

قدمت هذه الدراسة نظامًا يعتمد على تعلم الآلة للتنبؤ باحتمالية تأخر الطلبة في سداد الأقساط الدراسية. بعد تنظيف البيانات وتجهيزها واختبار ثلاثة نماذج تصنيف، أظهر Random Forest أفضل أداء إجمالي وفق F1-score، ولذلك اعتمد نموذجًا نهائيًا. حقق النموذج قدرة على اكتشاف نحو ثلثي حالات التأخر في مجموعة الاختبار، كما أظهر تحليل الخصائص أن تاريخ التأخر السابق يمثل أحد أهم مصادر المعلومات التي يعتمد عليها النموذج. وتوضح النتائج أن قيمة النظام لا تكمن في استبدال القرار الإداري البشري، وإنما في توفير أداة دعم قرار احتمالية يمكن استخدامها للكشف المبكر عن الحالات التي قد تستدعي المتابعة.

حدود الدراسة (Limitations):

تظل هذه النتائج مقيدة بعدة اعتبارات، منها:

1. محدودية حجم مجموعة البيانات (261 سجلا بعد التنظيف) مما يقيد قوة الاستنتاج والتعميم.
2. عدم توازن الفئات، إذ إن حالات التأخر أقل بكثير من حالات السداد في الموعد.

3. كون البيانات تمثل سياقًا مؤسسيًا محددًا قد تختلف علاقاته عند الانتقال إلى مؤسسة أو فترة زمنية أخرى.
4. أهمية الخصائص المستخرجة من النموذج لا تمثل دليلًا على علاقة سببية.
5. البيانات الحالية لا تتضمن متغير هدف حقيقيًا يمثل عدد أيام التأخير، ما يقصر الدراسة الحالية على تصنيف حدوث التأخر من عدمه.

التوصيات والأعمال المستقبلية:

- **زيادة حجم البيانات:** جمع سجلات من سنوات وفروع ومؤسسات تعليمية متعددة.
- **معالجة عدم التوازن:** تجربة أساليب إضافية لمعالجة عدم توازن الفئات مع تقييم أثرها على Precisiong Recall.
- **ضبط النموذج:** إجراء ضبط أوسع للمعاملات الفائقة (Hyperparameter Tuning) ودراسة معايرة الاحتمالات واختيار عتبة قرار مناسبة للاستخدام المؤسسي.
- **التقييم الخارجي:** إجراء تقييم زمني أو خارجي على بيانات لم تدخل في دورة بناء النموذج.
- **التنبؤ العددي:** إضافة متغير هدف عددي يمثل عدد أيام التأخير الفعلية لتدريب نموذج انحدار مستقل لتقدير مدة التأخير.
- **مراقبة الأداء:** تطوير آليات لمراقبة أداء النموذج بعد النشر واكتشاف أي تغير في توزيع البيانات بمرور الوقت (Data Drift).

المراجع (References)

[1] Breiman, L. (2001). Random Forests. *Machine Learning*, 45, 5–32. https://doi.org/10.1023/A:1010933404324

[2] Cortes, C., & Vapnik, V. (1995). Support-Vector Networks. *Machine Learning*, 20, 273–297. https://doi.org/10.1007/BF00994018

[3] Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). Applied Logistic Regression (3rd ed.). Wiley. https://doi.org/10.1002/9781118548387

[4] Saito, T., & Rehmsmeier, M. (2015). The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets. PLOS ONE, 10(3), e0118432. https://doi.org/10.1371/journal.pone.0118432

[5] Pedregosa, F., Varoquaux, G., Gramfort, A., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

[6] Scikit-learn Developers. Permutation Feature Importance - User Guide. Scikit-learn Documentation.